

Botify Challenge / Top Anchors

En SEO les textes des liens pointant vers une page ont une influence importante, ils aident les moteurs de recherche à deviner le sens de la page liée

(exemple

si `<a href="http://B.com/">the white house</a>`

alors il est probable que la page [B.com/](#) ait un rapport avec la 'maison blanche'

)

Botify aide les sites à détecter les pages qui utilisent bien, ou très mal, ce principe

Imaginez un fichier décrivant le linking interne d'un site. (CSV, TSV, JSON...)

Chaque enregistrement a le format suivant :

url_source url_destination texte_d'ancres

(exemple : [http://site.com/page1](#) [http://site.com/page2.com](#) [cliquez ici])

- 1/ le fichier contient en général une centaine d'enregistrements par page source
- 2/ un crawl complet est composé de 1 à 25 millions de pages sources
- 3/ un même lien A->B peut être présent plusieurs fois sur une même page; avec un texte d'ancres identique ou différent
- 4/ le fichier est généré pendant le crawl; il est donc trié sur la colonne url_source

Problème à résoudre :

Générer deux fichiers :

1/ la liste des 1000 pages recevant le plus de textes d'ancres différents (les pages les mieux optimisées)

Format de type :

url_destination (texte_d'ancres, combien de liens utilisent ce texte)+

(exemple : [http://site.com/page2](#) [cliquez ici], 10, en savoir plus, 5)

2/ la liste de toutes les pages recevant un seul texte d'ancres (le cas le pire en seo)

Format de type :

url_destination ancre

(exemple : [http://site.com/product?id=222](#) ours en peluche)

NOTE : la résolution du problème doit se faire dans une RAM limitée (1 Go)